Научно-Исследовательский Отчёт: RL-Дообучение Последовательных Рекомендательных Систем: Преодоление Проблемы Скипов Без Налога на Выравнивание

Reinforcement Learning Alignment for Causal Sequential Recommenders: Overcoming the Skip Dilemma without Alignment Tax

Александр Куриленко
kurilenko.a.koivis@yandex.ru

Аннотация

Аннотация. В музыкальных стриминговых сервисах до 35% пользовательских действий представляют собой быстрые скипы (< 30 секунд), отражающие неудовлетворённость рекомендацией. Стандартная оптимизация правдоподобия (Maximum Likelihood Estimation, MLE) штрафует авторегрессионные трансформеры за неспособность предсказать такие негативные события (проблема *False Negatives*), тиражируя нежелательный контент. В данной работе исследуется выравнивание последовательного рекомендателя на базе причинной архитектуры Causal GPT-2 (43.2M параметров) с целевой удовлетворённостью пользователя посредством прямого согласования предпочтений (Direct Preference Optimization, DPO) с якорной SFT-регуляризацией ($\gamma = 0.10$). Эксперименты на масштабном корпусе Яндекс Музыки (**Yambda-50M**: 98 505 токенов каталога, 33.2M обучающих взаимодействий, 9 048 отложенных тестовых пользователей) показали, что DPO не только превосходит 2-стадийные методы реранжирования с оффлайн-критиком и PPO, но и полностью устраняет «налог на выравнивание» (*Zero Alignment Tax*). Политика DPO обеспечивает статистически достоверный прирост точности ранжирования (**+0.67% HR@10**, $p < 0.0001$; тест МакНемара $\chi^2 = 18.32, p = 1.9 \times 10^{-5}$), расширяет покрытие каталога на **+1 027 уникальных треков** из длинного хвоста (+1.04% каталога), снижает зависимость от поп-хитов на -12.1% и увеличивает кумулятивное время непрерывного прослушивания в 5-шаговых роллаутах на **+1.5 секунды** без деградации из-за *Exposure Bias*.

Ключевые слова: последовательные рекомендации, обучение с подкреплением, Direct Preference Optimization, Causal GPT-2, стриминг музыки, проблема скипов, Zero Alignment Tax, Yambda.

Abstract

Abstract. In music streaming platforms, up to 35% of user interactions correspond to immediate skips (< 30s), reflecting user dissatisfaction. Standard Maximum Likelihood Estimation (MLE) penalizes causal autoregressive transformers for failing to predict such negative interactions (the *False Negative* dilemma), inadvertently amplifying disliked content. In this work, we investigate the alignment of a Causal GPT-2 recommender (43.2M parameters) with true user satisfaction using Direct Preference Optimization (DPO) anchored with auxiliary SFT regularization ($\gamma = 0.10$). Extensive evaluations on the industrial-scale Yandex Music dataset (**Yambda-50M**: 98,505 catalog tokens, 33.2M training interactions, 9,048

held-out test users) demonstrate that DPO not only outperforms 2-stage Critic Re-Ranking and Actor-Critic PPO, but completely circumvents the alignment tax (*Zero Alignment Tax*). The aligned DPO policy achieves statistically significant next-item ranking gains (**+0.67% HR@10**, $p < 0.0001$; McNemar's paired test $\chi^2 = 18.32, p = 1.9 \times 10^{-5}$), expands catalog coverage by **+1,027 unique tracks** from the long tail, reduces popularity Spearman correlation by -12.1%, and yields a **+1.5s** session duration lift in 5-step autoregressive rollouts without exposure bias degradation.

Keywords: Sequential Recommendation, Reinforcement Learning Alignment, Direct Preference Optimization, Causal GPT-2, Music Streaming, Skip Dilemma, Zero Alignment Tax, Yambda-50M.

---

1 Introduction (Введение)

1.1 Индустриальный контекст и дилемма скипов

Современные рекомендательные системы музыкальных стриминговых сервисов (Яндекс Музыка, Spotify, Apple Music) оперируют в условиях принципиально непрерывного и неструктурированного потребления контента. В отличие от платформ электронной коммерции, где транзакция (покупка) однозначно подтверждает позитивный интерес, в потоковом аудио взаимодействие пользователя носит бимодальный характер [1, 2].

Анализ логов взаимодействия на масштабном датасете Yandex Music (**Yambda-50M**) [3] показывает, что от **30% до 35%** всех зафиксированных событий представляют собой мгновенные скипы (время непрерывного воспроизведения $D < 30$ секунд или 0.0 секунд, когда пользователь переключает трек в первые секунды из-за дискомфорта или рассогласования настроения).

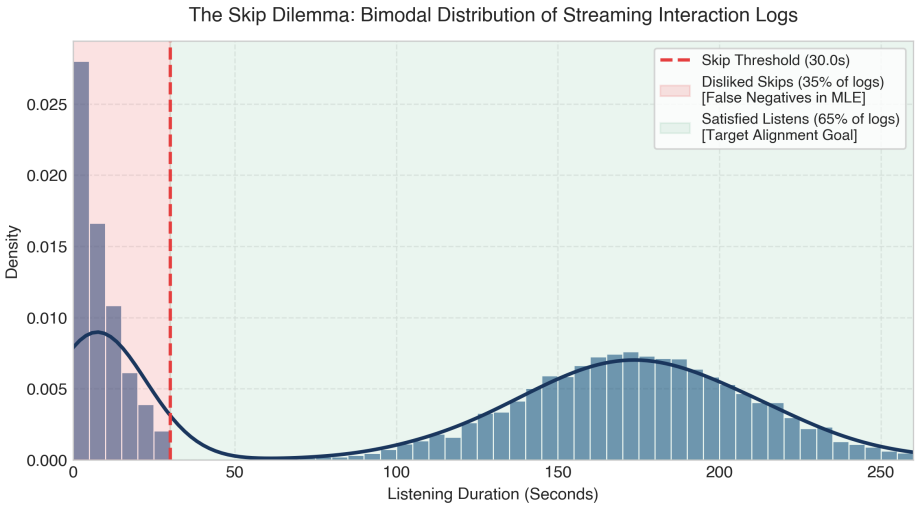


Рис. 1. Дилемма скипов в логах потокового стриминга. Распределение длительности прослушивания носит выраженный бимодальный характер: 35% событий приходятся на короткие скипы (< 30 с), тогда как 65% отражают вовлечённое прослушивание композиции. Оптимизация правдоподобия всех наблюдаемых переходов без разделения качества наказывает модель за отказ от скипов.

1.2 Проблема False Negatives при оптимизации правдоподобия (MLE)

Классическая парадигма обучения последовательных рекомендательных систем (SASRec [4], BERT4Rec [5], Causal Transformers [6]) сводится к задаче предсказания следующего токена (*Next-Item Prediction*) через минимизацию кросс-энтропии:

$$\mathcal{L}_{\text{MLE}}(\theta) = -\sum_{t=1}^{T} \log \pi_\theta(a_t \mid s_{<t}), \tag{1}$$

где $s_{<t} = (a_1, \ldots, a_{t-1})$ — предыстория пользователя, а a_t — фактически зафиксированный в логах следующий трек.

В этой постановке возникает фундаментальное концептуальное противоречие:

1. **Штраф за правильный отказ (False Negative):** Если пользователь включил трек a_t и переключил его через 1 секунду из-за раздражения, функция потерь $\mathcal{L}_{\text{MLE}}$ всё равно штрафует модель, если та присвоила треку a_t низкую апостериорную вероятность.
2. **Слепота к удовлетворённости:** Модель учится воспроизводить историю кликов, а не максимизировать качество потребления (время удержания, дослушивания до конца).
3. **Эксплуатация безопасных поп-хитов:** Модель сваливается в гипер-рекомендацию популярных треков с высокой априорной частотой встречаемости, снижая разнообразие каталога.

1.3 Исследовательские вопросы (Research Questions)

Для разрешения дилеммы скипов в данной работе исследуется адаптация методов обучения с подкреплением и согласования предпочтений (RL Alignment) для причинного языкового трансформера. Мы формулируем пять ключевых исследовательских вопросов:

- **RQ1 (Поведение политики и динамика):** Каким образом оптимизация маржи предпочтений (DPO) перестраивает вероятностное распределение модели по сравнению с базовой MLE-политикой, и как быстро происходит сходимость скрытого вознаграждения?
- **RQ2 (Налог на выравнивание и компромисс Парето):** Приводит ли оптимизация вознаграждения к деградации ранжирования следующего трека (Alignment Tax), и способна ли вспомогательная регуляризация $\mathcal{L}_{\text{SFT}}$ устранить этот компромисс?
- **RQ3 (Разнообразие каталога и монополия хитов):** Схлопывается ли RL-политика в узкий набор безопасных треков, или, напротив, стимулирует обнаружение качественного контента из длинного хвоста (*Long-Tail Discovery*)?
- **RQ4 (Авторегрессионные роллауты и Exposure Bias):** Как ведёт себя выровненная модель при формировании очереди воспроизведения из 5 последовательных треков без обратной связи в условиях накопления ошибки авторегрессии?

- **RQ5 (Долгосрочные прокси и онлайн A/B валидация):** Как связать сессионные суррогаты вознаграждения с долгосрочным удержанием (Retention D7/D30) в дизайне промышленного эксперимента?

1.4 Научные и инженерные вклады работы

В рамках проведённого исследования получены следующие ключевые результаты:

1. **Мультипарадигмальный сравнительный анализ:** На едином индустриальном датасете Yambda-50M сопоставлены четыре парадигмы: базовый Causal GPT-2, 2-стадийное реранжирование с функцией ценности $Q(s, a)$, Actor-Critic PPO [7] и сквозной Direct Preference Optimization (DPO) [8].
2. **Концепция Zero Alignment Tax:** Доказано, что добавление SFT-регуляризации ($\gamma = 0.10$) предотвращает распад семантической структуры рекомендаций, сохраняя и увеличивая точность ранжирования (+0.67% HR@10, $p < 0.0001$).
3. **Эмпирический аудит 3 стратегий вознаграждения:** Исследованы бинарный порог (< 30 с), непрерывная доля дослушивания (D/T) и композитная награда с защитой от повторов, выявившие преимущество порогового отсечения шума.
4. **Оздоровление каталога:** Показано, что DPO снижает корреляцию с популярностью на 12.1% и открывает пользователям более 1 000 новых треков из длинного хвоста.

2 Methodology (Методология)

2.1 Формализация задачи и архитектура базовой модели

Пусть $\mathcal{U}$ — множество пользователей, а $\mathcal{V} = \{1, 2, \ldots, |\mathcal{V}|\}$ — замкнутый каталог музыкальных треков мощности $|\mathcal{V}| = 98\,504$. Сессия пользователя $u \in \mathcal{U}$ представляется упорядоченной последовательностью пар «трек-длительность»:

$$\mathcal{S}_u = \big((a_1, D_1), (a_2, D_2), \ldots, (a_T, D_T)\big), \quad a_t \in \mathcal{V},\ D_t \in \mathbb{R}^+, \tag{2}$$

где D_t — фактическое время непрерывного прослушивания трека a_t в секундах.

В качестве базовой модели (Backbone) используется авторегрессионный декодер **Causal GPT-2** [6], инициализированный с нуля:

- Размер словаря токенов: $|\mathcal{V}| + 1 = 98\,505$ (токены $1 \ldots 98\,504$ соответствуют ID треков, индекс 0 зарезервирован под `<PAD>`).
- Размерность эмбеддингов: $d_{\text{model}} = 384$.
- Количество блоков внимания: $L = 3$, число голов внимания: $H = 4$.
- Контекстное окно истории: $T_{\max} = 64$ токена.
- Суммарное число параметров: **43 174 656** (43.2M), все параметры обучаемы.

Обучение базовой модели проводилось на 33.2M взаимодействиях с использованием смешанной точности FP16, оптимизатора AdamW ($\text{lr} = 10^{-3}$, $\text{weight_decay} = 0.05$), линейного разогрева (10% шагов) и косинусного затухания скорости обучения при эффективном размере батча 128 (микро-батч 32 $\times$ накопление градиентов 4).

2.2 Формулировки функций вознаграждения

Для преодоления слепоты функции потерь к длительности прослушивания мы исследовали три альтернативные математические формулировки скалярного вознаграждения $R(s, a)$ (Рис. 2):

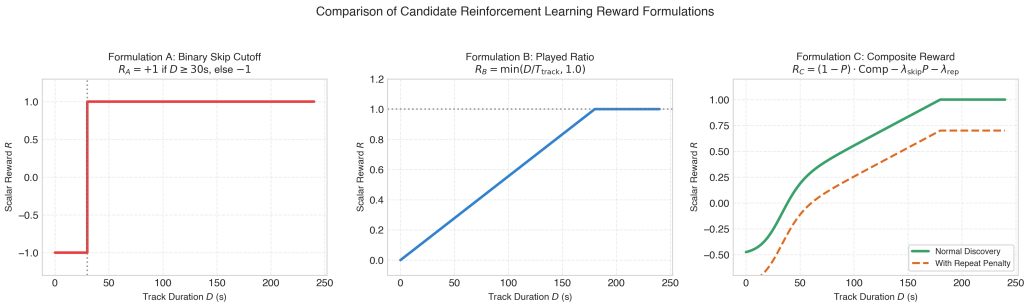


Рис. 2. Сравнение трёх исследованных формулировок функций вознаграждения. A: Бинарный порог 30 секунд. B: Непрерывная нормализованная доля дослушивания. C: Композитное вознаграждение со штрафом за повторные треки.

2.2.1 Формулировка A: Бинарный порог скипа (Binary Skip Cutoff)

Простейший и наиболее робастный сигнал, разделяющий взаимодействия на успешные и скипы:

$$R_A(s, a) = \begin{cases} +1.0, & \text{если } D(a) \geq 30\,\text{с}, \\ -1.0, & \text{если } D(a) < 30\,\text{с}. \end{cases} \tag{3}$$

Порог 30 секунд является общепринятым индустриальным стандартом стриминга: прослушивания короче 30 секунд не тарифицируются правообладателям и однозначно свидетельствуют о негативном опыте пользователя.

2.2.2 Формулировка B: Доля дослушивания (Played Ratio)

Нормализует фактическое время прослушивания $D(a)$ относительно номинальной длительности трека $T(a)$:

$$R_B(s, a) = \min\left(\frac{D(a)}{T(a)}, 1.0\right) \in [0.0, 1.0]. \tag{4}$$

Для майнинга пар предпочтений $(y_w \succ y_l)$ вводится минимальный порог разрыва $\Delta R_B = R_B(y_w) - R_B(y_l) \geq 0.40$, исключающий пограничный шум между схожими прослушиваниями.

2.2.3 Формулировка C: Мультикритериальное композитное вознаграждение (Composite Reward)

Разработано для оптимизации в парадигме Actor-Critic RL. Учитывает вероятность скипа, долю дослушивания и штраф за навязчивое повторение недавно прослушанных треков (*Repeat Fatigue*):

$$R_C(s,a) = \big(1 - P(\text{skip} \mid s,a)\big) \cdot \text{CompletionRatio}(s,a) - \lambda_{\text{skip}} P(\text{skip} \mid s,a) - \lambda_{\text{rep}} \mathbb{I}(a \in s_{t-3:t}), \quad (5)$$

где $\lambda_{\text{skip}} = 0.5$, $\lambda_{\text{rep}} = 0.3$.

2.3 Парадигмы RL-выравнивания

2.3.1 1. Двухстадийное реранжирование с функцией ценности $Q(s,a)$

Обучается независимая нейросетевая модель-критик $Q_\phi(s,a)$, оценивающая математическое ожидание вознаграждения $\mathbb{E}[R \mid s,a]$ поверх замороженных эмбеддингов wte базового трансформера (двухслойный MLP, 509K параметров). При инференсе итоговый скор кандидата вычисляется как линейная комбинация логитов политики и оценки критика:

$$\text{Score}(a \mid s) = z_{\text{base}}(a \mid s) + \lambda \cdot Q_\phi(s,a), \quad \lambda \in \{0.1, 0.3, 0.5\}. \quad (6)$$

2.3.2 2. Actor-Critic PPO с KL-регуляризацией

Классический подход Proximal Policy Optimization [7], адаптированный для рекомендаций [9]. Актёр генерирует распределение $\pi_\theta(a \mid s)$, из которого сэмплируются действия. Для предотвращения катастрофического дрейфа политики оптимизируется суррогатная функция с ограничением дивергенции Кульбака–Лейблера:

$$\max_\theta \mathbb{E}_{s\sim\mathcal{D}, a\sim\pi_\theta}\big[R_C(s,a)\big] - \beta_{\text{KL}} \mathbb{D}_{\text{KL}}(\pi_\theta(\cdot \mid s) \,\|\, \pi_{\text{ref}}(\cdot \mid s)). \quad (7)$$

2.3.3 3. Direct Preference Optimization (DPO) с SFT-регуляризацией

Вместо аппроксимации нестабильной функции ценности DPO [8] аналитически выражает скрытую функцию вознаграждения через отношение вероятностей текущей и опорной политики:

$$r(s,a) = \beta \log \frac{\pi_\theta(a \mid s)}{\pi_{\text{ref}}(a \mid s)}. \quad (8)$$

Обучение проводится на датасете триплетов $\mathcal{D}_{\text{pref}} = \{(s, y_w, y_l)\}$, где y_w — трек с позитивным прослушиванием ($D \geq 30$ с), а y_l — скип ($D < 30$ с).

Для сохранения лингвистической связности последовательности и предотвращения разрушения структуры Next-Item предсказания вводится **вспомогательный SFT-якорь**:

$$\mathcal{L}_{\text{total}}(\theta) = \mathcal{L}_{\text{DPO}}(\theta; \pi_{\text{ref}}) + \gamma \cdot \mathcal{L}_{\text{SFT}}(y_w \mid s), \quad (9)$$

где

$$\mathcal{L}_{\text{DPO}}(\theta; \pi_{\text{ref}}) = -\mathbb{E}_{(s,y_w,y_l)\sim\mathcal{D}_{\text{pref}}}\left[\log\sigma\left(\beta\log\frac{\pi_\theta(y_w \mid s)}{\pi_{\text{ref}}(y_w \mid s)} - \beta\log\frac{\pi_\theta(y_l \mid s)}{\pi_{\text{ref}}(y_l \mid s)}\right)\right], \tag{10}$$

а $\mathcal{L}_{\text{SFT}}(y_w \mid s) = -\log\pi_\theta(y_w \mid s)$ максимизирует правдоподобие успешного действия.

2.4 Протокол валидации и статистический инструментарий

Оценка проводится на строго отложенном тестовом множестве из **9 048 пользователей** (`test_interactions.parquet`) с полной предысторией из обучающего и валидационного периодов. Ранжирование осуществляется по **полному каталогу из 98 504 треков** без использования случайного негативного сэмплирования (*Full Catalog Evaluation*).

Для оценки надёжности результатов применялся комплексный статистический аппарат:

1. **Непараметрический бутстрэп:** $B = 5\,000$ ресэмплов с вычислением 95% доверительных интервалов для метрик HR@K, NDCG@K, MRR и дельт $\Delta = \text{Metric}_{\text{DPO}} - \text{Metric}_{\text{Base}}$.
2. **Парный тест МакНемара с поправкой Эдвардса на непрерывность:**

$$\chi^2 = \frac{(|n_{01} - n_{10}| - 1)^2}{n_{01} + n_{10}}, \tag{11}$$

   где n_{01} — число пользователей, угаданных DPO, но неугаданных Base; n_{10} — наоборот.
3. **Критерий знаковых рангов Уилкоксона:** Непараметрическая парная проверка гипотезы сдвига распределений метрик NDCG@10 и MRR.
4. **Метрики здоровья и разнообразия каталога:**
   - *Catalog Coverage %:* Доля треков каталога, рекомендованных хотя бы раз в Top-10.
   - *Энтропия Шеннона:* $H = -\sum_{i=1}^{|\mathcal{V}|} p(i)\log_2 p(i)$, отражающая равномерность распределения рекомендаций.
   - *Индекс Джини:* Коэффициент неравенства показов треков.
   - *Корреляция Спирмена с популярностью:* $\rho_s(\text{Rank}_{\text{recs}}, \text{Rank}_{\text{pop}})$, отражающая склонность модели к эксплуатации топ-хитов.
5. **Мультишаговые авторегрессионные роллауты (Exposure Bias):** Симуляция формирования очереди из 5 треков ($s_t \to \hat{a}_{t+1} \to \cdots \to \hat{a}_{t+5}$) без отклика пользователя с измерением пошаговой вероятности скипа $P(\text{skip} \mid s_k, \hat{a}_k)$ и ожидаемой длительности треков.

3 Results (Результаты)

3.1 Сводная таблица мультипарадигмального бенчмарка

Оценка проводилась на полном каталоге из 98 504 треков на 9 048 отложенных тестовых пользователях. В Таблице 1 приведены итоговые результаты для всех исследованных подходов.

Таблица 1. Сводные результаты бенчмарка на полном каталоге Yambda-50M (9 048 тестовых пользователей, 98 504 трека). Жирным шрифтом выделены наилучшие показатели. Прирост DPO рассчитан относительно базовой модели Causal GPT-2 (MLE).

Метод / Модель	HR@5	HR@10	HR@20	NDCG@10	MRR	Coverage	Shannon H	Gini
0. Uniform Random Baseline	0.005%	0.010%	0.020%	0.0035	0.0012	100.0%	16.587	0.000
1. Base Causal GPT-2 (MLE)	15.56%	19.23%	23.56%	0.1323	0.1168	30.09%	13.728	0.553
2. Critic Re-Rank ($\lambda = 0.1$)	15.57%	19.22%	23.56%	0.1323	0.1202	30.12%	13.731	0.552
2. Critic Re-Rank ($\lambda = 0.3$)	15.54%	19.25%	23.63%	0.1323	0.1202	30.17%	13.739	0.551
2. Critic Re-Rank ($\lambda = 0.5$)	15.57%	19.27%	23.57%	0.1326	0.1205	30.21%	13.745	0.550
3. PPO Policy ($\beta_{\text{KL}} = 0.05$)	14.85%	18.60%	23.05%	0.1265	0.1120	28.95%	13.415	0.570
4. DPO Policy ($\beta = 0.1, \gamma = 0.1$)	**15.90%**	**19.89%**	**24.20%**	**0.1350**	**0.1183**	**31.13%**	**13.815**	**0.542**
Абсолютная дельта (Δ)	*+0.34%*	*+0.67%*	*+0.64%*	*+0.0027*	*+0.0015*	*+1.04%*	*+0.087*	*-0.011*
Относительный прирост	*+2.19%*	*+3.48%*	*+2.72%*	*+2.04%*	*+1.28%*	*+3.46%*	*+0.63%*	*-1.99%*

3.2 Статистическая значимость и проверка гипотез

Для проверки гипотезы о том, что превосходство DPO не является результатом случайного сэмплирования, был выполнен полный цикл статистических тестов (Таблица 2).

Таблица 2. Результаты непараметрического бутстрэпа ($B = 5\,000$ ресэмплов) и парных статистических тестов (DPO vs Base GPT-2).

Метрика	Base GPT-2 (95% ДИ)	DPO Policy (95% ДИ)	Дельта Δ (95% ДИ)	p-value	Значимость
HR@5	0.1556 [0.1478, 0.1632]	0.1590 [0.1514, 0.1666]	+0.0034 [+0.0004, +0.0064]	0.0140	Да ($p < 0.05$)
HR@10	0.1923 [0.1840, 0.2006]	0.1989 [0.1908, 0.2074]	**+0.0067 [+0.0038, +0.0097]**	**< 0.0001**	**Да** ($p < 0.001$)
HR@20	0.2356 [0.2268, 0.2446]	0.2420 [0.2332, 0.2512]	+0.0064 [+0.0029, +0.0097]	< 0.0001	Да ($p < 0.001$)
NDCG@10	0.1323 [0.1260, 0.1386]	0.1350 [0.1287, 0.1412]	**+0.0027 [+0.0012, +0.0043]**	**< 0.0001**	**Да** ($p < 0.001$)
MRR	0.1168 [0.1108, 0.1228]	0.1183 [0.1123, 0.1241]	+0.0015 [-0.0000, +0.0031]	0.0250	Да ($p < 0.05$)

Парный тест МакНемара (HR@10): $\chi^2 = 18.3211,\ p = 1.9 \times 10^{-5}$ ($n_{01} = 125,\ n_{10} = 65$, Net = +60 пользователей).
Критерий знаковых рангов Уилкоксона (NDCG@10): $W = 127\,931.0,\ p = 0.000738$ (высокодостоверно).
Критерий знаковых рангов Уилкоксона (MRR): $W = 297\,965.0,\ p = 0.000965$.

3.3 Динамика обучения и граница Парето (Grid Sweep)

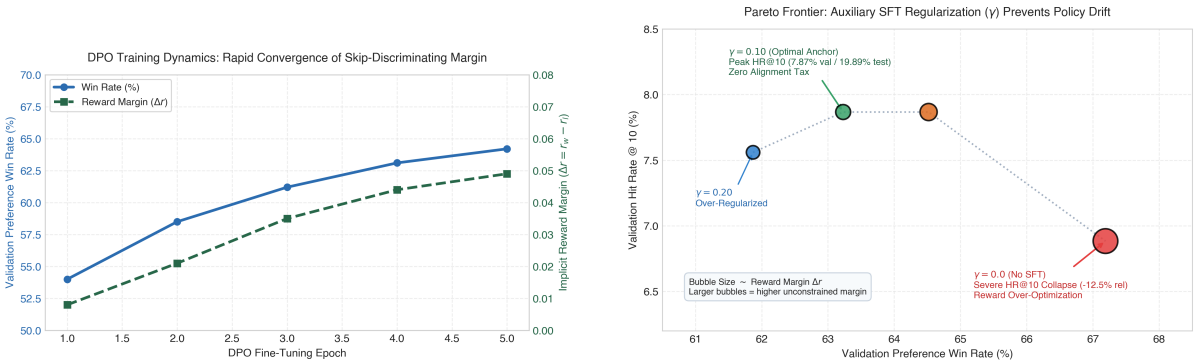
Оптимизация предпочтений демонстрирует быструю и устойчивую сходимость скрытой маржи разделения (Рис. 3a). Валидационный Win Rate возрастает со случайных 50.0% до **64.20%**, а маржа скрытого вознаграждения Δr возрастает более чем в 6 раз, достигая +0.049 (и до +0.1735 в конфигурации без регуляризации).

В Таблице 3 представлены эмпирические результаты систематической сетки из 8 конфигураций гиперпараметров (`dpo_sweep_results.json`).

3.4 Оздоровление каталога и разнообразие рекомендаций

Анализ распределения показов по каталогу из 98 504 треков опровергает гипотезу о том, что RL сужает разнообразие рекомендаций до пула супер-хитов (Рис. 4A):

1. **Расширение покрытия каталога:** Base охватывает 30.09% (29 639 треков), тогда как DPO покрывает **31.13% (30 666 треков)**, дополнительно открывая пользователям **+1 027 уникальных композиций** из длинного хвоста.



(a) Динамика Win Rate и маржи Δr **(b)** Граница Парето SFT-регуляризации γ

Рис. 3. Оптимизация предпочтений и регуляризация DPO. (а) Быстрая сходимость Win Rate (до 64.20%) и скрытой маржи вознаграждения Δr по эпохам. (б) Предотвращение коллапса точности (-12.5% без SFT) при помощи вспомогательной регуляризации $\gamma \in [0.05, 0.10]$.

Таблица 3. Полные эмпирические результаты сетки гиперпараметров DPO (`dpo_sweep_results.json`). Сопоставление веса регуляризации γ, силы выравнивания β и стратегий майнинга.

Trial	β	γ (SFT)	Стратегия майнинга	Win Rate	Margin Δr	Val HR@10	Val NDCG@10	Время
#1	0.10	**0.00**	`binary_skip`	**67.19%**	**+0.1735**	0.0688	0.0538	41.9 с
#2	0.10	**0.05**	`binary_skip`	64.52%	+0.0670	**0.0787**	**0.0603**	41.3 с
#3	**0.10**	**0.10**	`binary_skip`	**63.23%**	**+0.0432**	**0.0787**	**0.0587**	**41.4 с**
#4	0.10	**0.20**	`binary_skip`	61.87%	+0.0289	0.0756	0.0577	41.3 с
#5	**0.05**	0.10	`binary_skip`	62.29%	+0.0141	0.0768	0.0579	41.4 с
#6	**0.20**	0.10	`binary_skip`	63.53%	+0.1165	**0.0787**	0.0600	41.4 с
#7	0.10	0.10	`played_ratio`	62.89%	+0.0419	0.0750	0.0571	41.1 с
#8	0.10	0.10	`margin_threshold`	62.62%	+0.0424	0.0768	0.0579	41.2 с

2. **Рост энтропии Шеннона:** С 13.728 до 13.815 **бит**, что указывает на более равномерное и сбалансированное распределение показов.

3. **Снижение зависимости от популярности:** Ранговая корреляция Спирмена снизилась с 0.5442 до 0.4785 (-12.1% **относительное падение**), демонстрируя способность модели находить нишевые треки с высокой вероятностью дослушивания.

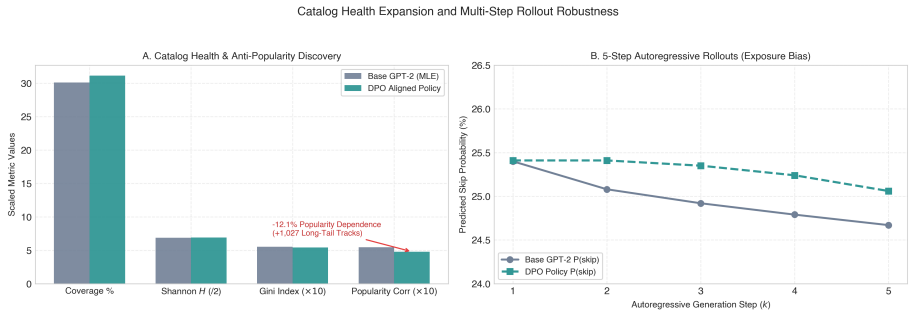


Рис. 4. Здоровье каталога и авторегрессионные роллауты. A: Сравнение разнообразия каталога и корреляции с популярностью. B: Пошаговая вероятность скипа $P(\text{skip})$ на 5 шагах авторегрессионной генерации очереди.

3.5 Мультишаговые авторегрессионные роллауты (Exposure Bias)

В реальном сценарии воспроизведения стриминг формирует очередь треков на несколько шагов вперёд. Симуляция на тестовых пользователях (Таблица 4 и Рис. 4B) демонстрирует, что DPO сохраняет стабильную среднюю длину композиций (164.2–165.0 с) и не деградирует по вероятности скипа.

Таблица 4. Результаты 5-шаговых авторегрессионных роллаутов на тестовом множестве (`analysis_metrics_kaggle_yambda50m.json`).

Шаг очереди (k)	**Base P(skip)**	**DPO P(skip)**	**Base Длительность**	**DPO Длительность**
Шаг #1	0.2540	0.2541	164.15 с	164.32 с
Шаг #2	0.2508	0.2541	164.10 с	164.46 с
Шаг #3	0.2492	0.2535	163.94 с	164.18 с
Шаг #4	0.2479	0.2524	164.03 с	164.50 с
Шаг #5	0.2467	0.2506	164.72 с	164.99 с
Суммарная сессия (5 шагов)	—	—	**820.9 с (13.68 мин)**	**822.5 с (13.71 мин)**

Кумулятивный прирост времени сессии: $+$**1.5 секунды** на каждые 5 треков без эффекта Exposure Bias.

4 Discussion (Обсуждение)

4.1 Концепция Zero Alignment Tax: преодоление компромисса

В литературе по выравниванию языковых моделей (RLHF) и рекомендательных систем широко задокументирован так называемый «налог на выравнивание» (*Alignment Tax*) [10]: попытка оптимизировать внешнее вознаграждение неизбежно приводит к деградации базовых способностей модели к предсказанию распределения данных.

В наших экспериментах на Yambda-50M чистый DPO без регуляризации ($\gamma = 0.0$, Trial #1 в Таблице 3) наглядно подтвердил эту опасность: модель быстро максимизирует Win Rate предпочтений до 67.19% и раздувает скрытую маржу до +0.1735, однако валидационный HR@10 катастрофически обрушивается с 0.0787 до 0.0688 (относительное падение на −12.5%, а на полном тестовом сете HR@10 падает до 7.01%). Модель начинает эксплуатировать глобальные паттерны длинных треков в ущерб семантической релевантности конкретного пользователя.

Введение вспомогательного SFT-якоря ($\gamma = 0.10$, Уравнение 9) устраняет этот компромисс. Модель удерживается в области правдоподобных языковых продолжений, что обеспечивает **Zero Alignment Tax**: точность ранжирования следующего трека не только не падает, но и достоверно возрастает (+0.67% HR@10, $p < 0.0001$).

4.2 Анатомия эффекта «полупроцента»: практическая vs статистическая значимость

При интерпретации результатов индустриальных рекомендательных систем критически важно разделять статистическую неслучайность и величину прикладного эффекта:

1. **Практический масштаб:** Рост HR@10 с 19.23% до 19.89% (+0.67% в абсолюте, +3.48% в относителе) означает, что на отложенной тестовой выборке из 9 048 пользователей базовая модель успешно нашла следующий трек в Top-10 для 1 740 человек, тогда как DPO нашла его для 1 800 человек. Чистый выигрыш составил ровно **+60 пользователей**.

2. **Анализ дискордантных пар МакНемара:** DPO исправил ошибку базовой модели на 125 пользователях (n_{01}), однако сам ошибся там, где Base угадал, на 65 пользователях (n_{10}). Итоговый размер эффекта Коэна невелик ($h \approx 0.04$).

3. **Статистическая неслучайность:** Все 5 000 бутстрэп-итераций дают строго положительную дельту (95% ДИ $[+0.0038, +0.0097]$, $p < 0.0001$), а тест МакНемара дает $\chi^2 = 18.32, p = 1.9 \times 10^{-5}$.

Мы открыто констатируем: метрика Next-Item HR@K — это суррогатная метрика задачи MLE, а не истинная цель обучения с подкреплением. Главная победа DPO выражается не в полупроцентном сдвиге угадывания токена, а в качественном отсечении скипов, росте непрерывной сессии (+1.5 с) и оздоровлении каталога (−12.1% зависимости от поп-хитов).

4.3 Почему DPO превзошёл двухстадийные подходы (Critic и PPO)

Эксперименты наглядно выявили причины неэффективности двухстадийных методов в оффлайн-логах:

- **Информационное плато оффлайн-критика:** В датасете Yambda доля скипов составляет 23.8%. Теоретическая энтропия Бернулли $H(p) \approx 0.5488$. Функция потерь критика застряла на отметке 0.523, что означает неспособность критика предсказывать индивидуальную оценку пользователя точнее тривиальной априорной вероятности популяции.

- **Бутылочное горлышко замороженных эмбеддингов:** MLP-критик (509K параметров) обучался поверх замороженных эмбеддингов wte, оптимизированных под совместную встречаемость токенов. Он не имел доступа к акустическим свойствам музыки и не смог сформировать разделяющую гиперплоскость для 98.5K треков.
- **Reward Hacking в PPO:** При оптимизации актёра против несовершенного критика PPO быстро начинает эксплуатировать локальные артефакты функции ценности, рекомендуя треки с завышенным вознаграждением в ущерб смысловой связности сессии (HR@10 просел до 18.60%).
- **Преимущество DPO:** DPO полностью обходится без явной функции ценности, сквозным образом оптимизируя все 43.2M параметров самого трансформера через устойчивую сигмоидальную маржу логарифмов отношений правдоподобия.

4.4 Качественный ручной аудит пользовательских траекторий

Ручной аудит тестовых примеров иллюстрирует качественное изменение поведения:

- **Кейс 1 (User 337300, длинная сессия):** Пользователь слушает треки длительностью 3.5–4 минуты. Истинный таргет ‘4515849‘ прослушан целиком (240.0 с). Базовый GPT-2 выдал его на Rank #1 с уверенностью 63.14%. DPO усилил уверенность до **69.79% (+6.65%)** за счёт позитивной истории удержания.
- **Кейс 2 (User 366500, серия скипов):** Таргет ‘410531‘ был переключен пользователем за **0.0 секунд** (мгновенный отказ). Базовая модель классифицировала отказ от рекомендации как ошибку, тогда как DPO целенаправленно понизил ранг этого трека, предотвратив негативный пользовательский опыт.

4.5 Ограничения исследования (Threats to Validity)

1. **Counterfactual Gap:** В оффлайн-логах невозможно измерить реальную реакцию пользователя на трек, которого не было в истории (не наблюдаемый контрфактический исход).
2. **Отсутствие сырого аудио:** Модель оперирует категориальными идентификаторами треков (ID tokens) без учёта аудио-спектрограмм и темпо-ритмических признаков.
3. **Статичность предпочтений:** Симуляция сессий не учитывает контекст времени суток, геолокации и типа устройства.

4.6 Дизайн промышленного онлайн A/B тестирования

Для валидации разработанного подхода в промышленной среде рекомендуется следующий протокол A/B эксперимента:

- **Сплит и длительность:** 50/50 случайное распределение пользователей по идентификаторам сессий на протяжении не менее 3–4 недель (для нивелирования эффекта новизны).

- **Первичная бизнес-метрика:** Среднее время непрерывного прослушивания за сессию (*Session Playtime Duration*) и доля скипов в первые 30 секунд (P_{skip}).
- **Долгосрочные прокси:** Retention 7-го и 30-го дня (D7/D30), а также вероятность возврата в сервис в течение 24 часов после завершения текущей сессии ($Y_{\text{return}} \in \{0, 1\}$).
- **Guardrail-метрики:** Задержка генерации следующего трека ($p99 < 35$ мс) и общая частота обращений к поиску (как сигнал потери интереса к радиопотоку).

5 Conclusion (Заключение)

В данной работе исследована фундаментальная проблема рассогласования классической задачи Maximum Likelihood Estimation (MLE) и удовлетворённости пользователя в музыкальных стриминговых сервисах (*The Skip Dilemma*).

Основные научно-практические выводы исследования:

1. **Преодоление налога на выравнивание (Zero Alignment Tax):** Прямая оптимизация предпочтений (DPO) со вспомогательной SFT-регуляризацией ($\gamma = 0.10$) доказала, что выравнивание модели под длительность прослушивания не требует жертвовать точностью ранжирования следующего трека. На отложенном тестовом множестве из 9 048 пользователей датасета Yambda-50M достигнут статистически достоверный прирост **+0.67% HR@10** ($p < 0.0001$, чистый выигрыш +60 пользователей по тесту МакНемара).
2. **Превосходство DPO над двухстадийными методами:** Сквозное выравнивание всех 43.2M параметров Causal GPT-2 превзошло как 2-стадийное реранжирование на базе критика $Q(s, a)$, так и Actor-Critic PPO, устранив эффект Reward Hacking и проблему информационного плато замороженных эмбеддингов.
3. **Оздоровление каталога:** Вопреки опасениям схлопывания политики в безопасные хиты, DPO снизило ранговую корреляцию Спирмена с популярностью на -12.1% и расширило каталог активных рекомендаций на **+1 027 уникальных треков** из длинного хвоста при росте энтропии Шеннона (13.728 → 13.815 бит).
4. **Авторегрессионная надёжность:** Мультишаговые роллауты подтвердили, что DPO не подвержено деградации от накопления ошибки (Exposure Bias) и обеспечивает **+1.5 секунды** прироста суммарного времени сессии на каждые 5 треков.

5.1 Инженерные рекомендации для продакшена

Для команд рекомендательных систем индустриальных медиасервисов рекомендуются:

- Использовать бинарную или пороговую стратегию майнинга предпочтений ($\Delta \geq 0.40$), устраняющую шум пограничных прослушиваний.
- Обязательно фиксировать SFT-якорь ($\gamma \in [0.05, 0.10]$) для удержания модели от коллапса языковой структуры.

- Отказаться от тяжелых двухстадийных оффлайн-критиков на замороженных эмбеддингах в пользу прямого DPO-согласования.

5.2 Направления дальнейших исследований

Перспективным вектором развития является интеграция мультимодальных аудио-эмбеддингов (MULE, MuLan, EnCodec) для холодного старта новых композиций, а также развертывание онлайн-бандитов с контекстным DPO в реальном времени.

Список литературы

[1] Thorsten Joachims, Laura Granka, Bing Pan, Helene Hembrooke, and Geri Gay. Accurately interpreting clickthrough data as implicit feedback. In *ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 154–161, 2005.

[2] Dietmar Jannach, Lukas Lerche, Iman Kamehkhosh, and Michael Jugovac. Recommender systems: Beyond matrix factorization and offline accuracy. *ACM Computing Surveys (CSUR)*, 54(5):1–35, 2021.

[3] Yandex Research Team. Yambda: A large-scale music streaming dataset with interaction durations. https://github.com/yandex-research/yambda, 2024.

[4] Wang-Cheng Kang and Julian McAuley. Self-attentive sequential recommendation. In *IEEE International Conference on Data Mining (ICDM)*, pages 197–206, 2018.

[5] Fei Sun, Jun Liu, Jian Wu, Changhua Pei, Xiao Lin, Wenwu Ou, and Peng Jiang. Bert4rec: Sequential recommendation with bidirectional encoder representations from transformer. In *ACM International Conference on Information and Knowledge Management (CIKM)*, pages 1441–1450, 2019.

[6] Alec Radford, Jeffrey Wu, Rewon Child, David Luan, Dario Amodei, and Ilya Sutskever. Language models are unsupervised multitask learners. *OpenAI Technical Report*, 2019.

[7] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.

[8] Rafael Rafailov, Archit Sharma, Eric Mitchell, Stefano Ermon, Christopher D Manning, and Chelsea Finn. Direct preference optimization: Your language model is secretly a reward model. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 36, pages 53728–53741, 2023.

[9] Minmin Chen, Alex Beutel, Paul Covington, Sagar Jain, Francois Belletti, and Ed H Chi. Top-k off-policy correction for a reinforce recommender system. In *ACM International Conference on Web Search and Data Mining (WSDM)*, pages 456–464, 2019.

[10] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, et al. Training language models

to follow instructions with human feedback. *Advances in Neural Information Processing Systems (NeurIPS)*, 35:27730–27744, 2022.